Análise de Dados como Método de Apoio às Políticas Públicas

Análise Multivariada

Análise de Componentes Principais - Obtenção das Componentes

Profa. Adriana Andrade

UFRRJ

Obtenção das componentes principais

- Requer variáveis em escala intervalar ou de razão;
- Não requer qualquer suposição sobre a forma da distribuição multivariada dessas variáveis.

Obtenção das componentes principais

- A *Análise de Componentes Principais (ACP)* é realizada a partir da matriz de covariância $\mathbf{\Sigma}$ ou da matriz de correlação $\boldsymbol{\rho}$ de $(X_1, X_2, ..., X_p)$. No caso dos dados serem provenientes de uma amostra, a partir de $\mathbf{S}$ ou $\mathbf{R}$.

Obtenção das componentes principais

O fundamento da ACP são os autovalores e os autovetores da matriz de covariância/correlação que possibilitam que a matriz de dados originais seja aproximada por uma matriz de componentes.

Obtenção das componentes principais

Seja $\mathbf{X}$ o vetor das p variáveis originais, ou seja, $\mathbf{X}^t = (X_1, X_2, ..., X_p)$, com matriz de covariâncias $\mathbf{\Sigma}$.

A ACP irá fornecer as componentes principais $Y_1, Y_2, ..., Y_p$ de $\mathbf{\Sigma}$ a partir dos seus autovetores $(\boldsymbol{e}_1, ..., \boldsymbol{e}_p)$ e dos seus autovalores $(\lambda_1 \geq ... \geq \lambda_p)$.

Obtenção das componentes principais

Os autovetores e os autovalores são quantidades obtidas de uma matriz pelo método da **Decomposição Espectral**.

Com base na decomposição espectral, tem-se que a matriz de covariâncias Σ pode ser escrita da seguinte maneira:

$\Sigma = \boldsymbol{\Gamma}\Lambda\boldsymbol{\Gamma}^t$, onde:

- A matriz $\boldsymbol{\Gamma}$ é formada pelos autovetores $(\boldsymbol{e}_1, ..., \boldsymbol{e}_p)$. Trata-se de uma matriz ortogonal, de modo que $\boldsymbol{\Gamma}^t\boldsymbol{\Gamma} = \boldsymbol{\Gamma}\boldsymbol{\Gamma}^t = \boldsymbol{I}$.
- A matriz $\boldsymbol{\Lambda}$ é uma matriz diagonal formada pelos autovalores $\lambda_1, ..., \lambda_p$ de Σ

Tem-se, então: $(\lambda_1, \boldsymbol{e}_1), (\lambda_2, \boldsymbol{e}_2), ..., (\lambda_p, \boldsymbol{e}_p)$ os pares de autovalores e autovetores associados a Σ.

Obtenção das componentes principais

As componentes principais $Y_1, Y_2, ..., Y_p$ são obtidas a partir das combinações lineares entre as variáveis originais e os autovetores:

$$Y_1 = \mathbf{e}_1^t \mathbf{X} = e_{11}X_1 + e_{12}X_2 + ... + e_{1p}X_p$$
$$Y_2 = \mathbf{e}_2^t \mathbf{X} = e_{21}X_1 + e_{22}X_2 + ... + e_{2p}X_p$$
$$\dots$$
$$Y_p = \mathbf{e}_p^t \mathbf{X} = e_{p1}X_1 + e_{p2}X_2 + ... + e_{pp}X_p$$

$\boldsymbol{Y}_j$ representa as componentes principais

$\boldsymbol{X}$ vetor de variáveis

$\boldsymbol{e}_j$ autovetores da matriz de covariância. *O valor e_{ji} é interpretado como o coeficiente da variável X_i na componente Y_j, informa o peso (direção e contribuição relativa) da $i-$ésima variável na $j-$ésima componente.*

Obtenção das componentes principais

Os autovetores entram na composição das componentes. Já os autovalores irão fornecer a variabilidade capturada por cada componente.

$$Var(Y_j) = Var(\mathbf{e}_j^t \mathbf{X}) = \mathbf{e}_j^t \mathbf{\Sigma} \mathbf{e}_j = \lambda_j$$

$j = 1, ..., p$

Cada autovalor λ_j representa a variância de uma componente principal Y_j.

Temos que $\lambda_1 \geq \lambda_2 \geq ... \geq \lambda_p \geq 0$

A primeira componente gerada agrega a maior quantidade de variabilidade dos dados, tendo as demais uma menor variabilidade.

Obtenção das componentes principais

- **Covariância entre duas componentes principais**

$$Cov(Y_j, Y_k) = 0, \; j \neq k$$

Isso significa dizer que as componentes principais não são correlacionadas.

Obtenção das componentes principais

Exemplo

Sejam as variáveis $X_1, X_2, X3$ com matriz de covariância dada por:

$$\Sigma = \begin{bmatrix} 1 & -2 & 0 \\ -2 & 5 & 0 \\ 0 & 0 & 2 \end{bmatrix}$$

- Obtenha as suas componentes principais

Obtenção das componentes principais

Exemplo

Primeiramente, vamos criar a matriz no R.

```
m<-matrix(c(1,-2,0,-2,5,0,0,0,2),nrow=3)
m
```

```
     [,1] [,2] [,3]
[1,]    1   -2    0
[2,]   -2    5    0
[3,]    0    0    2
```

Obtenção das componentes principais

Exemplo

Utilizando o comando *eigen* no R, é possível realizar a decomposição espectral da matriz de interesse.

```r
eigen(m)
```

```
eigen() decomposition
$values
[1] 5.8284271 2.0000000 0.1715729

$vectors
           [,1] [,2]      [,3]
[1,] -0.3826834    0 0.9238795
[2,]  0.9238795    0 0.3826834
[3,]  0.0000000    1 0.0000000
```

Decomposição da matriz de correlações

Tendo em vista que a variância total das componentes é equivalente à soma das variâncias das variáveis originais, nos casos em que essas diferem muito, é possível que as variáveis com maiores variâncias predomininem nas primeiras componentes, e as de baixa variabilidade nas últimas.

Assim sendo, se a intenção da análise for a redução de dimensionalidadde dos dados, corre-se o risco de eliminar as variáveis de menor variância.

Decomposição da matriz de correlações

Para evitar tal situação, as componentes principais podem ser obtidas com a utilização das variáveis padronizadas, ou seja, a partir da matriz de correlações.

As variáveis padronizadas têm a mesma variância (unitária), de modo que as variáveis terão igual contribuição para a variância total.

Lembrando que a variável padronizada é obtida por: $Z_i = \frac{X_i - \bar{X}}{DP(X)}$

Decomposição da matriz de correlações

Será aplicada a técnica de decomposição espectral sobre a matriz de correlações ρ para obtenção dos autovetores e autovalores.

A $j-$ésima componente principal das variáveis padronizadas $\mathbf{z} = (Z_1, Z_2, ..., Zp)$ é dada por:

$$Y_j = e_j^\top Z_i$$

onde e_j é o autovetor de ρ associado ao $j-$ésimo autovalor λ_j e Z_i é a variável padronizada.

Decomposição da matriz de correlações

- As componentes principais provenientes da matriz de covariâncias Σ são distintas das obtidas pela matriz de correlações ρ;
- Em geral, quando as variáveis possuem escalas diferentes **é recomendável utilizar as variáveis padronizadas, ou seja, fazer a análise sobre a matriz de correlações**;

Decomposição da matriz de correlações

Exemplo

Seja

$$\Sigma = \begin{bmatrix} 1 & 4 \\ 4 & 100 \end{bmatrix}$$

Logo

$$\rho = \begin{bmatrix} 1 & 0,4 \\ 0,4 & 10 \end{bmatrix}$$

Decomposição da matriz de correlações

Exemplo

No R utilize os seguintes comandos:

```
sigma <- matrix(c(1,4,4,100),nrow = 2)
eigen(sigma)
```

```
eigen() decomposition
$values
[1] 100.1613532   0.8386468

$vectors
           [,1]        [,2]
[1,] 0.04030552 -0.99918740
[2,] 0.99918740  0.04030552
```

No R utilize os seguintes comandos

```
rho=matrix(c(1,0.4,0.4,1),nrow = 2)
```

Decomposição da matriz de correlações

Exemplo

Os pares de autovalor-autovetor de Σ

$\lambda_1 = 100.16 \; e_1 = [0.040 \quad 0.999] \; \lambda_2 = 0.84 \; e_1^\top = [0.999 \quad 0.040]$

Os pares de autovalor-autovetor próprios de ρ

$\lambda_1 = 1.4 \; e_1^\top = [0.707 \quad 0.707] \; \lambda_2 = 0.6 \; e_1^\top = [-0.707 \quad 0.707]$

Decomposição da matriz de correlações

Exemplo

- No caso da primeira componente determinada sob Σ, tem-se uma proporção de variância explicada por essa componente de $100.16/(100.16 + 0.84) = 0.992$
- No caso da primeira componente determinada sob ρ, tem-se uma proporção de variância explicada por essa componente de $1.4/(1.4 + 0.6) = 0.7$

Decomposição da matriz de correlações

Resultados

- $\sum_{i=1}^{p} Var(Y_j) = p$
- A proporção da variabilidade total explicada pela $j - ésima$ componente principal é dada por $\frac{\lambda_j}{p}$

Correlação entre a Variável padronizada e a Componente Principal

Mede o grau de correlação linear entre a variável e a compontente. Valores elevados sinalizam uma boa representação da variável pela componente. Obtida por:

$$Cor(Z_i, Y_j) = e_{ji}\sqrt{\lambda_j}$$