Análise de Dados como Método de Apoio às Políticas Públicas

Análise Multivariada

Análise Fatorial - Introudção

Profa. Adriana Andrade

UFRRJ

1. **Introdução - Análise Fatorial**

Section 1

Introdução - Análise Fatorial

Introdução - Análise Fatorial

A análise fatorial é um técnica de redução de dimensionalidade que representa as *variáveis correlacionadas* $X_1, X_2, ..., X_p$ de um conjunto a partir de variáveis aleatórias não-observadas, os fatores denotados por $F_1, F_2, ...F_m$.

Introdução

- Como medir definições abstratas - Construtos?

Depressão

Inteligência

Qualidade

Produtividade

Uma estratégia é mensurar variáveis observáveis empiricamente relacionadas entre si que traduzam o conceito de interesse.

Introdução

A Análise Fatorial é uma técnica exploratória que busca encontrar os fatores subjacentes às variáveis observáveis utilizada quando há pouco conhecimento sobre a estrutura de dependência das variáveis. Assim sendo, o número de fatores não necessita ser conhecido previamente.

Sob outra abordagem, a análise fatorial pode ser utilizada com o intuito de confirmar uma estrutura já conhecida de fatores e seu relacionamento com as variáveis.

Utilizada para avaliar hipóteses sobre construtos definidos teoricamente quando o número de fatores é conhecido.

Introdução

Objetivos

Ao resumir dados, a análise fatorial obtém dimensões latentes que descrevem os dados em um número menor de fatores do que as variáveis individuais originais.

Identificar fatores subjacentes aos dados que expliquem parte da estrutura de dependência das variáveis observadas.

Introdução

Objetivos

- Redução do número de variáveis a partir da interdepência entre elas;
- Encontrar fatores responsáveis pela covariação entre as variáveis;
- Avaliação da dimensionalidade de um construto teórico;
- Desenvolvimento, refinação e avaliação da validade de construto de escalas, testes ou instrumentos;

Introdução

O modelo de análise fatorial supõe que cada variável X é linearmente dependente de poucas variáveis aleatórias não observadas ($m < p$), chamadas fatores comuns, e p fontes adicionais de variação, denominadas de fatores específicos (JOHNSON & WICHENR, 2002).

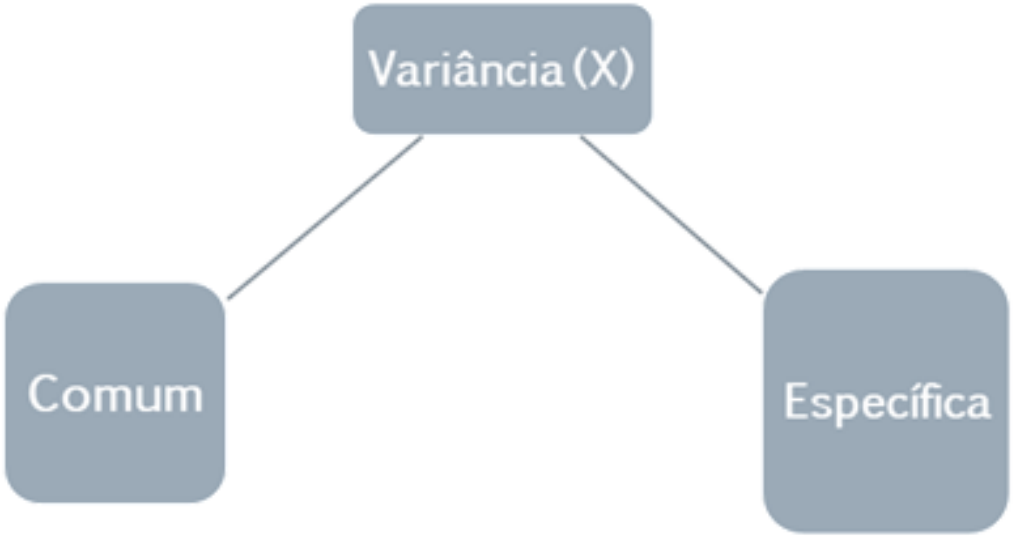

Definição

O modelo de análise fatorial é uma combinação de variáveis latentes: $F_1, F_2, ...F_m$. Para uma variável qualquer, temos:

$$X_i = l_{i1}F_1 + l_{i2}F_2 + ... + l_{im}F_m + \varepsilon_i$$

Onde:

l_{im} as são cargas fatoriais. Mensuram a associação entre a variável e o fator, em que medida a variável está relacionada com o construto subjacente.

F_i fator comum ao conjunto de variáveis.

ε_i é um fator específico para a i$-$é*sima* variável.

Definição

Temos que o modelo fatorial é formado pelo conjunto de equações:

$$X_1 = l_{11}F_1 + l_{12}F_2 + ... + l_{1m}F_m + \varepsilon_1$$
$$X_2 = l_{21}F_1 + l_{22}F_2 + ... + l_{2m}F_m + \varepsilon_2$$
$$\dots$$
$$X_p = l_{p1}F_1 + l_{p2}F_2 + ... + l_{pm}F_m + \varepsilon_p$$

Definição

Em notação matricial:

$$\boldsymbol{X} = \boldsymbol{L}\boldsymbol{F} + \boldsymbol{\Psi}$$

Definição

- **L** é a matriz de cargas fatoriais que expressa a relação da variável com o fator

$$\mathbf{L}_{p\times m} = \begin{bmatrix} l_{11} & l_{12} & \cdots & l_{1m} \\ l_{21} & l_{22} & \cdots & l_{2m} \\ \vdots & \vdots & \vdots & \vdots \\ l_{p1} & l_{p2} & \cdots & l_{pm} \end{bmatrix}$$

- **F** matriz com os fatores, variáveis latentes não observáveis

$$\mathbf{F} = \begin{bmatrix} F_1 \\ F_2 \\ \vdots \\ F_m \end{bmatrix}_{m\times 1}$$

Definição

- ε componente que representa a variação em X que não é explicada pelos fatores.

$$\boldsymbol{\varepsilon} = \begin{bmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_p \end{bmatrix}_{p \times 1}$$

Definição

O objetivo da **AF** é similar a **ACP**, quando se pretende reduzir a dimensão do conjunto analisado, facilitando a sua interpretação. No entanto, essas técnicas apresentam algumas diferenças:

- Na ACP as componentes principais são definidas como combinações lineares das variáveis;
- Na AF as variáveis originais são combinações lineares dos fatores latentes;

Definição

- Na ACP, busca-se explicar a variância total dos dados.
- Na AF, explicar a variância comum compartilhada entre variáveis observadas, explicando a estrutura de covariância por meio de fatores latentes.
- A ACP não requer, essencialmente, nenhuma suposição, enquanto que a análise fatorial faz algumas suposições-chave;
- As componentes principais são únicas, enquanto a análise fatorial está sujeita a diferentes soluções e a rotações arbitrárias.

Suposições da AF

Assuma que os fatores não observáveis são independentes entre si. Para cada fator F_j, $j = 1, 2, ..., m$, temos:

$E(F_j) = 0$

$VAR(F_j) = 1$

$Cov(F_j, F_k) = 0$, com $j \neq k$, ou seja, os fatores são ortogonais, $Cov(\mathbf{F}) = \mathbf{I}$

$Cov(F_j, \varepsilon_i) = 0$, F e ε são duas fontes de variação distintas, ambas relacionadas com as variáveis X, porém, sem qualquer relacionamento entre elas.

Propriedades

Cargas Fatorias

l_ij são as cargas dos fatores e representam o grau de relacionamento entre as variáveis e os fatores, ou seja: $Cov(X_i, F_j) = l_{ij}$

Na interpretação dos fatores, são valorizadas as variáveis com as maiores cargas.

Se a associação entre duas variáveis for alta, elas terão altas cargas nos mesmos fatores.

A partir das variáveis padronizadas, com base no modelo fatorial, a matriz de correlações pode ser obtida por:

$$\rho = \boldsymbol{LL'} + \boldsymbol{\Psi}$$

Propriedades

Considerando as suposições apontadas, temos que a variância de X_i pode ser expressa como:

$$Var(X_i) = Var(l_{i1}F_1 + l_{i2}F_2 + ... + l_{im}F_m + \varepsilon_i)$$
$$= l_{i1}^2 Var(F_1) + l_{i2}^2 Var(F_2) + \cdots + l_{im}^2 Var(F_m) + Var(\varepsilon_i)$$
$$= l_{i1}^2 + l_{i2}^2 + \cdots + l_{im}^2 + Var(\varepsilon_i)$$

Propriedades

Comunalidade h_i^2

Refere-se a variância compartilhada de cada variável com os fatores comuns, ou seja, é a variância explicada pela solução fatorial.

$h_i^2 = l_{i1}^2 + l_{i2}^2 + \cdots + l_{im}^2$

Variância Específica ψ_i

Também denominada de especificidade da variável, variância única ou residual,é a parte da variância não relacionada com os fatores comuns.

$\psi_i = Var(\varepsilon_i)$

Propriedades

Temos então uma partição da variância do vetor X

$Var(Xi) = h_i^2 + \psi_i$

Referências

ARTES, Rinaldo; BARROSO, Lúcia Pereira. Métodos multivariados de análise estatística. São Paulo: Blucher, 2023.

JOHNSON, R. A.; WINCHERN, D. W. Applied Multivariate Statistical Analysis. Prentice Hall, 2007

FÁVERO, Luiz; FÁVERO, Patrícia. Análise de dados: técnicas multivariadas exploratórias com SPSS e STATA. Elsevier Brasil, 2017.

- Notas de aula Prof. Djalma Pessoa ENCE/IBGE