Análise Multivariada

Análise de Agrupamentos - Métodos de Agrupamentos

Profa. Adriana Andrade

DEMAT/UFRRJ

1. **Métodos Não hierárquicos**

Métodos hierárquicos de agrupamento

Não requer a especificação prévia do número de grupos a serem formados. Método não supervisionado.

Geralmente, é empregado em análises exploratórias para identificar possíveis agrupamentos ou gerar informações sobre um possível número de grupos.

Nestes métodos os indivíduos são alocados nos grupos em diferentes etapas. Uma vez que um objeto passa a pertencer a um cluster, permance nesse cluster até o fim da análise.

Os métodos hierárquicos utilizam dois tipos de técnicas de agrupamento:

1) Aglomerativos: quando se utiliza uma série de fusões sucessivas (Mais utilizado).

n objetos (grupos singulares)=>1 grupo final

2) Divisivos: realiza o agrupamento a partir de divisões sucessivas.

1 grupo (c/ n objetos) => grupos singulares

Métodos hierárquicos de agrupamento

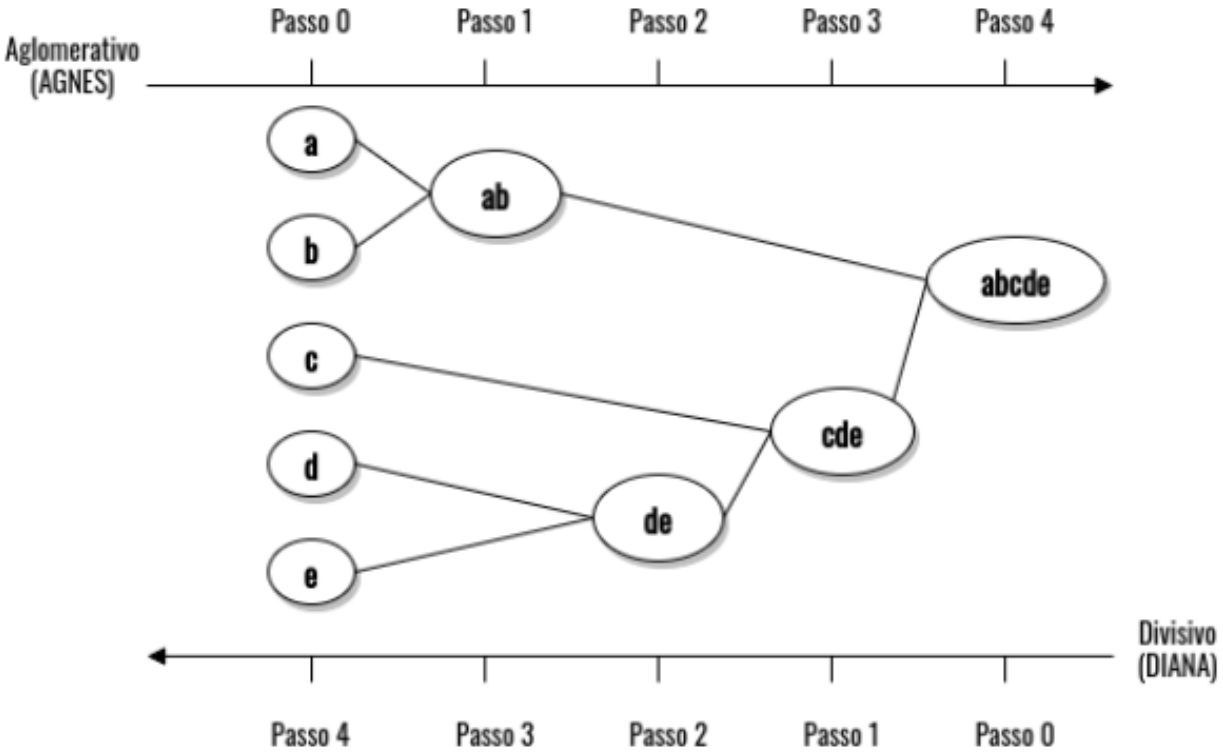

Fonte: Han, Pei, and Kamber (2011)

Métodos hierárquicos de agrupamento

Em ambos os casos, aglomerativos e divisivos, o resultado final é uma árvore de classificação que ilustra as fusões ou divisões realizadas em níveis sucessivos.

- Usam matriz de distâncias;
- Se um objeto entra num cluster não mais o abandona;
- Desconhece-se o número de clusters à partida;

Métodos hierárquicos de agrupamento - Métodos Aglomerativos

Etapas do agrupamento

1. Faça um cluster para cada elemento, ou seja, cada elemento é um cluster;
2. Com base na medida de similaridade escolhida, são combinados os 2 elementos mais semelhantes em um novo cluster;
3. As distâncias são recalculadas considerando agora a distância do novo cluster em relação aos demais elementos;
4. Repita os passos 2 e 3 até sobrar um único cluster.

Métodos hierárquicos de agrupamento

Método Vizinho mais próximo

Também chamado de método do encadeamento simples (*single linkage*). Neste método calcula-se a matriz de distâncias entre os n indivíduos, e com base nessas medidas os indivíduos mais próximos, ou seja, mais parecidos são agrupados.

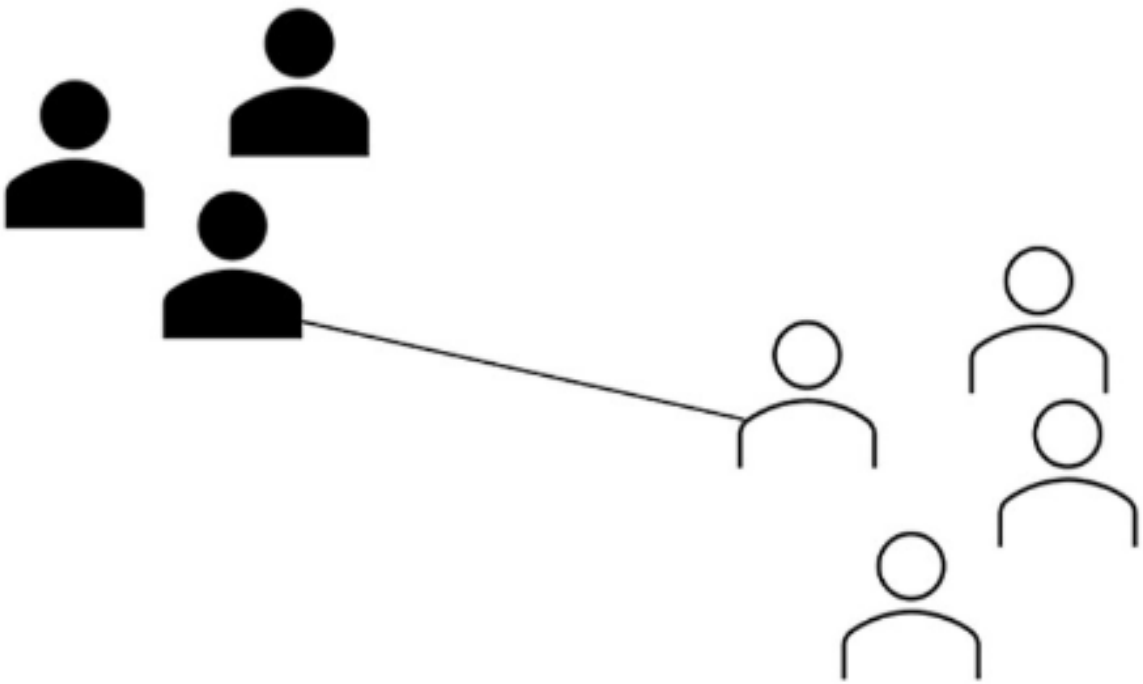

Métodos hierárquicos de agrupamento

Método Vizinho mais próximo

Tende a produzir cluster mais extensos. A desvantagem desse método é que ele pode causar a fusão prematura de grupos com pares próximos, mesmo que esses grupos sejam bem diferentes no geral.
A distância entre dois clusters A e B é dada pela menor distância entre qualquer par de elementos $X_j \in A$ e $X_l \in B$.

$$d(A, B) = \min_{X_j \in A, X_l \in B} d(X_j, X_l)$$

Métodos hierárquicos de agrupamento

Método Vizinho mais próximo

Exemplo

$$D = d_{jl} = \begin{array}{c|ccccc} & A & B & C & D & E \\ \hline A & 0 & & & & \\ B & 9 & 0 & & & \\ C & 3 & 7 & 0 & & \\ D & 6 & 5 & 9 & 0 & \\ E & 11 & 10 & \mathbf{2} & 8 & 0 \end{array}$$

$Min(d_{jl}) = d(C, E) = 2$ Novo cluster (CE)

Métodos hierárquicos de agrupamento

Exemplo

A matriz de distância será refeita considerando a distância entre o novo cluster e os demais elementos.

Para tal, será considerada a menor distância entre o novo cluster e os demais elemento

Métodos hierárquicos de agrupamento

Primeira Etapa $d(CE, A) = min\{d(C, A), d(E, A)\} = min\{3, 11\} = 3$
$d(CE, B) = min\{d(C, B), d(E, B)\} = min\{7, 10\} = 7$
$d(CE, D) = min\{d(C, D), d(E, D)\} = min\{9, 8\} = 8$

Segunda Etapa $d(CEA, B) = min\{d(CE, B), d(A, B)\} = min\{9, 7\} = 7$
$d(CEA, D) = min\{d(CE, D), d(A, D)\} = min\{8, 6\} = 6$

INÍCIO

	A	B	C	D	E
A	0				
B	9	0			
C	3	7	0		
D	6	9	5	0	
E	11	10	**2**	8	0

1 ETAPA

	CE	A	B	D
CE	0			
A	**3**	0		
B	7	9	0	
D	8	6	5	0

2 ETAPA

	CEA	B	D
CEA	0		
B	7	0	
D	6	**5**	0

3 ETAPA

	CEAD	B
CEAD	0	
B	6	0

Métodos hierárquicos de agrupamento

Método Vizinho mais distante

Também chamado de método de ligação completa *complete linkage*. Este método é o inverso do vizinho mais próximo. Calcula-se a matriz de distâncias entre os n indivíduos da população, em seguida os indivíduos mais distantes são agrupados.

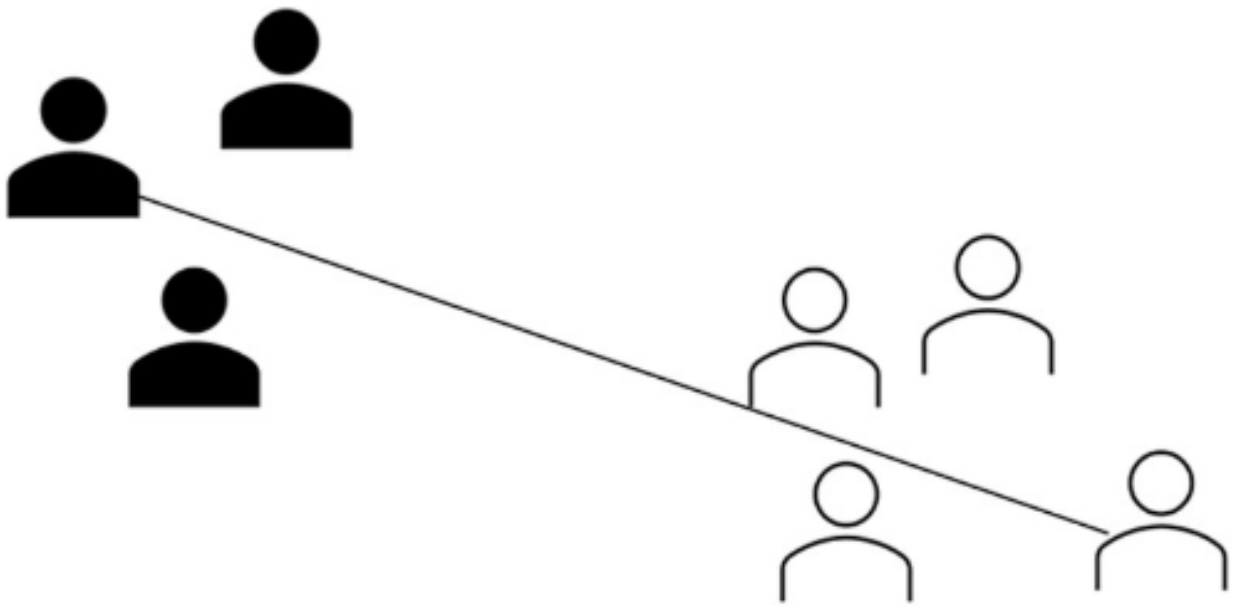

Métodos hierárquicos de agrupamento

Método Vizinho mais distante

A distância entre dois clusters A e B é dada pela maior distância entre qualquer par de elementos $X_j \in A$ e $X_l \in B$.

$$d(A, B) = \max_{X_j \in A, X_l \in B} d(X_j, X_l)$$

Métodos hierárquicos de agrupamento

Método da Ligação Média

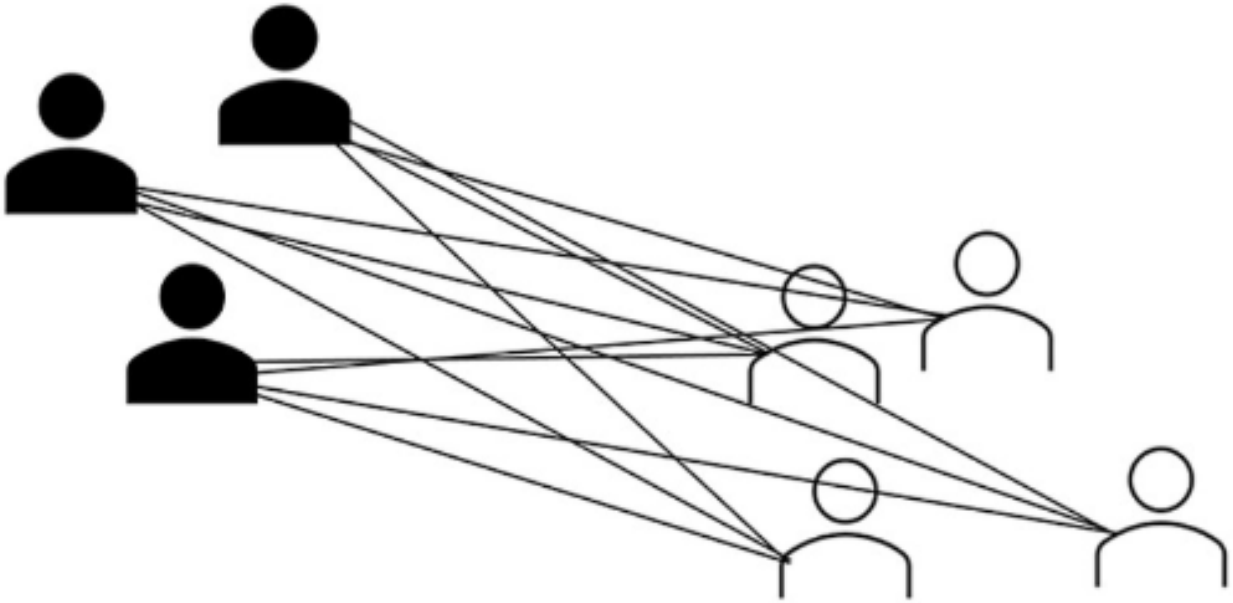

Métodos hierárquicos de agrupamento

Método da Ligação Média

Também denominado de Average linkage, a distância entre dois clusters A e B é dada pela média das distâncias entre todos os pares de elementos $X_j \in A$ e $X_l \in B$.

$$d(A,B) = \frac{1}{n_A n_B} \sum_{X_j \in A} \sum_{X_l \in B} d(X_j, X_l)$$

Métodos hierárquicos de agrupamento

Método de Ward

Este método minimiza a variância dentro dos clusters. Assim sendo, a alocação de um elemento a um grupo é feito de modo a minimizar uma medida de homogeneidade interna dos grupos após a alocação.

$$\Delta WSS = WSS_{depois} - WSS_{antes}$$

Onde WSS representa a variância interna ao grupo:

$$SQD = \sum_{j=1}^{k} \sum_{i \in G_j} (X_{i1} - \bar{X}_{j1})$$

Métodos hierárquicos de agrupamento

Método de Ward

Fundamento do método: Em cada passo do agrupamento há mudança de variação entre os grupos e dentro dos grupos
Procedimento também denominado de mínima variância

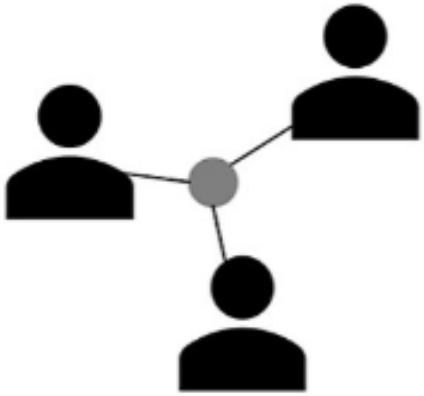

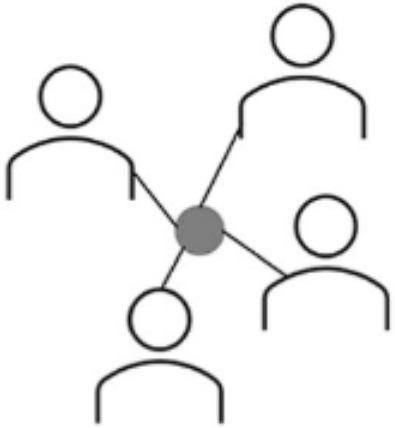

Métodos hierárquicos de agrupamento

Na prática, o método de Ward é o mais comumente usado.

O método de ligação simples, embora fácil de implementar e entender, normalmente não tem um desempenho tão bom quanto a ligação média ou a ligação completa.

A ligação média geralmente tem um bom desempenho na prática e é razoavelmente robusta a pequenas distorções.

Não há consenso sobre a superioridade de algum método.

Métodos hierárquicos de agrupamento - Dendograma

- Os grupos refletam a organização básica e desconhecida dos dados;
- Os algoritmos de agrupamento não apresentam solução para determinação do número ideal de grupos;

Uma maneira de determinar o número de grupos é a partir da análise do gráfico do dendrograma.

Métodos hierárquicos de agrupamento - Dendograma

O dendrograma é um gráfico em forma de árvore onde podemos observar alterações dos níveis de similaridade para as sucessivas etapas do agrupamento;

Eixo horizontal indivíduos;

O eixo vertical nível de similaridade;

As linhas verticais partindo dos indivíduos agrupados tem altura correspondente ao nível em que os indivíduos são considerados semelhantes.

Métodos hierárquicos de agrupamento - Dendograma

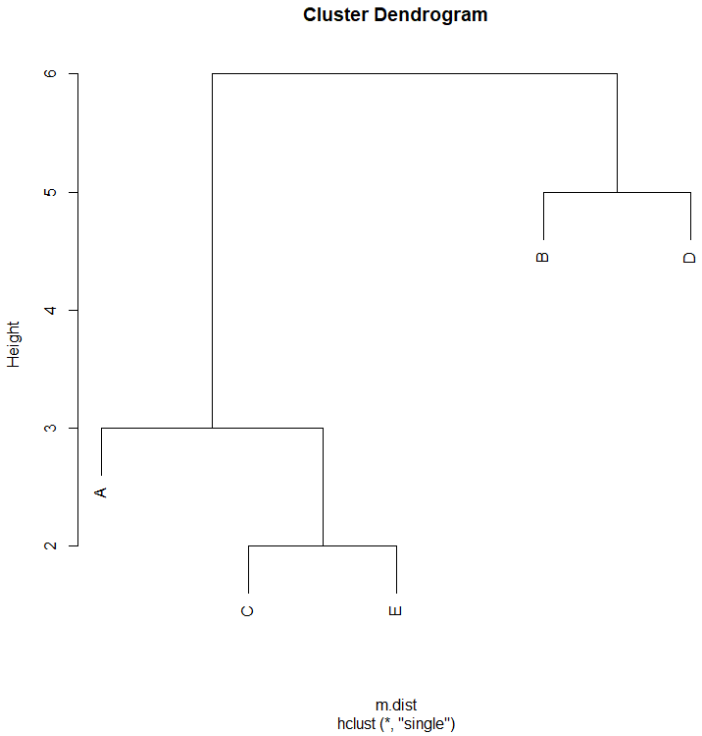

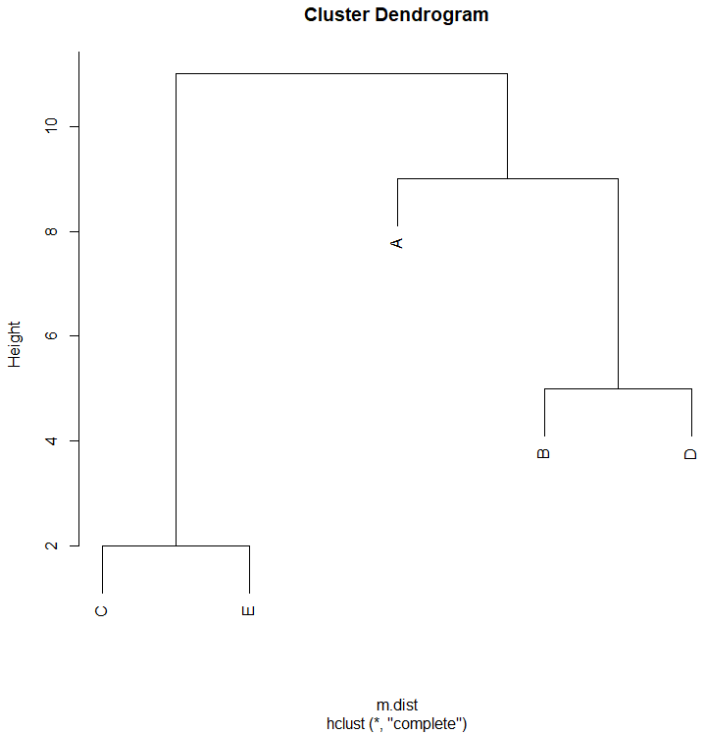

Métodos hierárquicos de agrupamento - Dendograma

Número de Agrupamentos

Como a análise de cluster hierárquica não define o número de clusters automaticamente, podemos usar como referência a altura do Dendrograma.

O corte no dendrograma pode ser feito em um ponto onde a distância dos clusters começa a aumentar muito.

Section 1

Métodos Não hierárquicos

Métodos Não hierárquicos

Os métodos não hierárquicos também são chamados de métodos de partição porque dividem os dados diretamente em um número fixo de clusters.

Métodos Não hierárquicos

Especificação prévia do número de clusters;

Cada elemento é alocado em um cluster cujo centróide é o mais próximo do elemento;

Os algoritmos são iterativos e, em cada estágio, novos clusters podem ser formados por divisão ou junção de clusters inicialmente definidos;

Se em um passo do algoritmo, dois elementos tiverem sido colocados em um mesmo grupo, não significa que estarão juntos na partição final;

Métodos Não hierárquicos

Nesse método é possível trabalhar com conjuntos de dados maiores, pois não é necessário armazenar a matriz de distâncias.

Não há a elaboração de dendongramas;

Métodos Não hierárquicos

- coesão interna (semelhança interna).
- isolamento (separação) dos clusters formados.
- Minimiza a variância intra-cluster.
- Within-cluster sum of squares:

$$WSS = \sum_{j=1}^{k} \sum_{x_i \in C_j} \|x_i - \bar{x}_j\|^2$$

Métodos hierárquicos de agrupamento

O agrupamento hierárquico requer a avaliação de três aspectos:

1. Escolha da métrica de distância;
2. Escolha da medida de ligação;
3. Definição o número de clusters

Métodos hierárquicos de agrupamento

As respostas mais populares a estas questões podem ser a distância euclidiana, o método de Ward e a observação visual dos dendogramas (Gere, 2023)

Referências

ARTES, Rinaldo; BARROSO, Lúcia Pereira. Métodos multivariados de análise estatística. São Paulo: Blucher, 2023.

JOHNSON, R. A.; WINCHERN, D. W. Applied Multivariate Statistical Analysis. Prentice Hall, 2007

FÁVERO, Luiz; FÁVERO, Patrícia. Análise de dados: técnicas multivariadas exploratórias com SPSS e STATA. Elsevier Brasil, 2017.

- Notas de aula Prof. Djalma Pessoa ENCE/IBGE
- Notas de aula Prof. Lupércio França Bessegato UFJF

GERE, Attila. Recommendations for validating hierarchical clustering in consumer sensory projects. Current Research in Food Science, v. 6, p. 100522, 2023.