Análise Multivariada

Análise de Agrupamentos - Introdução

Profa. Adriana Andrade

DEMAT/UFRRJ

Introdução

Análise de cluster é um termo coletivo para vários algoritmos que buscam encontrar estruturas de grupo em dados.

Os grupos são chamados de clusters e geralmente não são conhecidos a priori.

Os objetos são separados em grupos com base em certas características de um conjunto de dados.

As formas como esses grupos são separados são conhecidas como técnicas ou métodos de agrupamento.

Introdução

A utilização de técnicas de agrupamento pode ser fundamental para descobrir padrões e criar rótulos a partir dos grupos gerados no processo de agrupamento.

Em contraste, os procedimentos de classificação atribuem as observações a grupos já conhecidos.

É possível realizar uma classificação com os grupos identificados na análise de cluster.

Introdução

- Agrupamentos Possíveis

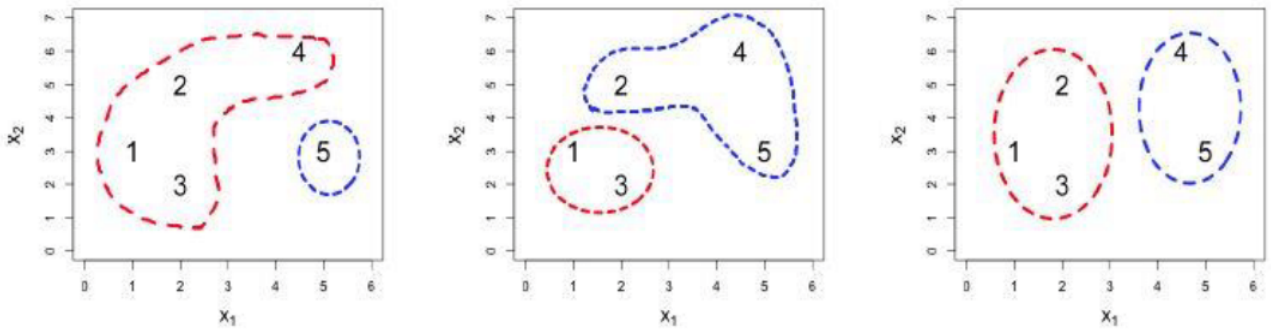

Introdução

- Agrupamentos Possíveis

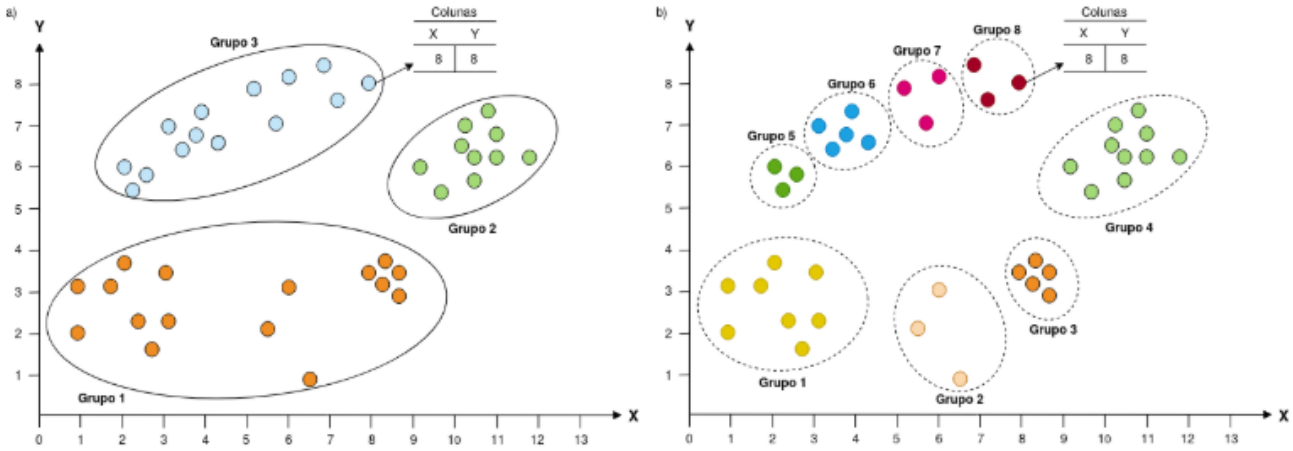

Adaptado de Esling and Agon (2012)

Introdução

Objetivos

Busca identificar agrupamentos das observações com base em semelhanças (similaridades) ou distâncias.

- Análise Exploratória
- Redução dos dados
- Elaboração de hipóteses sobre estrutura de relações
- Possibilita a identificação de outliers
- Predição

Introdução

Uma boa análise de agrupamentos irá produzir clustes com alta similaridade intra-classe e baixa similaridade inter-classe.

A qualidade do agrupamento depende da medida de similaridade e do método de implementação.

Introdução

Limitações

- Sempre cria agrupamentos, a despeito da estrutura real dos dados
- Técnica descritiva
- Não possibilita generalização, pois as medidas de agrupamento são obtidas a partir dos dados observados
- A técnica de análise de agrupamentos não distingue se as variáveis são ou não relevantes

Introdução

Perguntas

- Qual medida de distância deve ser usada?
- Quais variáveis devem ser incluídas?
- Qual a forma mais clara de apresentar os resultados?
- Como validar resultados?

Introdução - Etapas

1 - Preparação dos dados dados

2 - Obtenção da matriz de similaridades

3 - Escolha do método de agrupamento

4 - Decidir número de clusters

5 - Validação/descrição/interpretação.

Medidas de dissimilaridade e similaridade

Similaridade entre os elementos é uma medida empírica de semelhança entre os elementos a serem agrupados.

Dissimilaridade expressa a distância entre dois objetos em relação a um atributo.

Medidas de dissimilaridade e similaridade

Medida de similaridade: Quanto maior for a medida de similaridade maior semelhança entre os indivíduos.

Medida de dissimilaridade: Quanto maior for a medida de dissimilaridade, maior a distância, menor será a semelhança entre os indivíduos.

Medidas de dissimilaridade e similaridade

Não há regras estabelecidas para a seleção dessas medidas. Há, portanto, uma discricionariedade nessa escolha.

Deve-se observar nessa decisão:

- Natureza das variáveis
- Conhecimento do assunto estudado

Medidas de dissimilaridade

Medidas de dissimilaridades entre objetos

Seja os vetores aleatórios

$$\boldsymbol{X}_j' = [X_{j1}, X_{j2}, ..., X_{jp}]$$

e

$$\boldsymbol{X}_l' = [X_{l1}, X_{l2}, ..., X_{lp}]$$

com p variáveis para cada elemento.

Será obtida uma matriz $D = [d_{jl}]$ com a distância do elemento j ao elemento l em relação a p variáveis.

Distância

- Esquema de armazenamento de distâncias

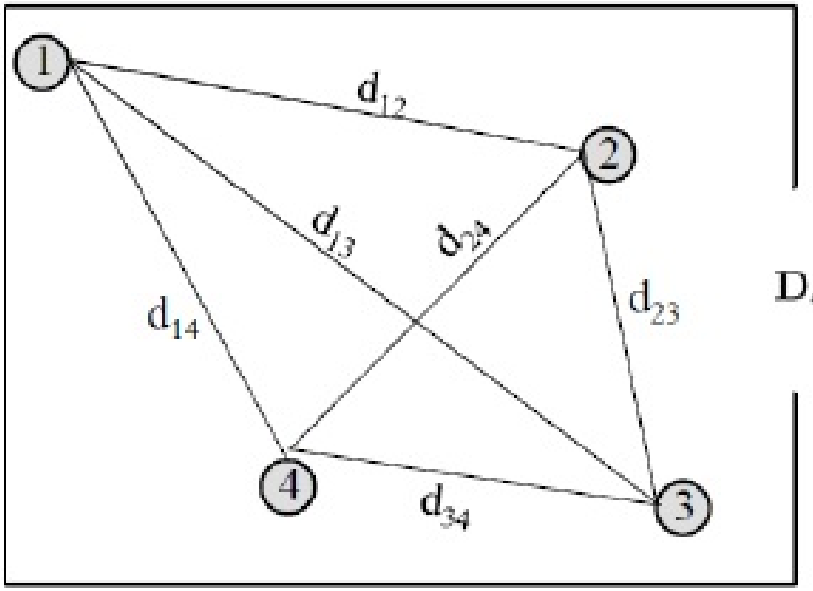

$$\mathbf{D}_{4\times 4} = \begin{bmatrix} 0 & d_{12} & d_{13} & d_{14} \\ d_{21} & 0 & d_{23} & d_{24} \\ d_{31} & d_{32} & 0 & d_{34} \\ d_{41} & d_{42} & d_{43} & 0 \end{bmatrix}$$

Distância

A distância na análise multivariada é usada para quantificar o grau de dissimilaridade entre os objetos, permite quantificar o quão "longe" ou "diferentes" os itens estão uns dos outros no espaço multidimensional.

Distância

Distância Euclidiana

Calcula a distância em linha reta entre dois pontos em um espaço multidimensional. É intuitiva e fácil de calcular.

Distância

Distância Euclidiana

Seja os vetores aleatórios

$$\boldsymbol{X}'_j = [X_{j1}, X_{j2}, ..., X_{jp}]$$

$$\boldsymbol{X}'_l = [X_{l1}, X_{l2}, ..., X_{lp}]$$

A distância euclidiana entre esses pontos é dada por:

$$d_{jl} = \sqrt{\sum_{i=1}^{p} (X_{ji} - X_{li})^2}$$

Distância

Distância Euclidiana

Medida de distância mais utilizada.

Possui restrições pois atribui coordenadas de mesma importância e não considera o impacto de dados com escalas diferentes, não considera a correlação entre as variáveis e pode ser afetada por valores atípicos.

Se recomenda a padronização das variáveis.

Medidas de Similaridade - Variáveis Qualitativas

Trabalha-se com coeficientes de similaridades, comparando os elementos de acordo com a presença ou ausência de certas características.

Medidas de Similaridade - Variáveis Quantitativas Qualitativas

Coeficiente de Gower (1971): técnica que permite a análise simultânea de dados numéricos e categóricos que estima a similaridade entre dois indivíduos quaisquer.

Métodos de Agrupamento

Os métodos de agrupamentos, também denominados de esquemas de aglomeração são classificados em dois tipos: **hierárquicos** e **não hieráquicos**.

Os métodos **hierárquicos** se baseiam na suposição de que existe uma estrutura hierárquica nos dados, de modo que a formação dos cluster ocorre incrementalmente, por etapas.

Os esquemas **não hierárquicos** fazem uso de algoritmos para obter agrupamentos que maximizam a homegeneidade dos grupos. ## Referências

ARTES, Rinaldo; BARROSO, Lúcia Pereira. Métodos multivariados de análise estatística. São Paulo: Blucher, 2023.

JOHNSON, R. A.; WINCHERN, D. W. Applied Multivariate Statistical Analysis. Prentice Hall, 2007

FÁVERO, Luiz; FÁVERO, Patrícia. Análise de dados: técnicas multivariadas