Análise Multivariada

Análise de Agrupamentos - Métodos de Agrupamentos

Profa. Adriana Andrade

DEMAT/UFRRJ

Métodos Não hierárquicos

Os métodos não hierárquicos também são chamados de métodos de partição porque dividem os dados diretamente em um número fixo de clusters.

Especificação prévia do número de clusters;

Cada elemento é alocado em um cluster cujo centróide é o mais próximo do elemento;

Os algoritmos são iterativos e, em cada estágio, novos clusters podem ser formados por divisão ou junção de clusters inicialmente definidos;

Se em um passo do algoritmo, dois elementos tiverem sido colocados em um mesmo grupo, não significa que estarão juntos na partição final;

Nesse método é possível trabalhar com conjuntos de dados maiores, pois não é necessário armazenar a matriz de distâncias.

Não há a elaboração de dendongramas;

Métodos Não hierárquicos

Princípios

- coesão interna (semelhança interna).
- isolamento (separação) dos clusters formados.
- Minimiza a variância intra-cluster.
- Within-cluster sum of squares:

$$WSS = \sum_{j=1}^{k} \sum_{x_i \in C_j} \|x_i - \bar{x}_j\|^2$$

Métodos Não hierárquicos

Etapas:

1. Definição do número de grupos;
2. Especificaçao de sementes que irão constituir os núcleos dos grupos;
3. Os elementos são alocados nos grupos com base na sua distância em relação ao centróide;
4. Uma vez que o elemento é alocado, tem-se a atualização do centróide;
5. As etapas 2 e 3 são repetidas até que não haja alteração dos centróides.

Métodos Não hierárquicos

k-médias

√ Medidas das variáveis X_1 e X_2:

	Observações	
Item	x_1	x_2
A	5	3
B	-1	1
C	1	-2
D	-3	-2

Métodos Não hierárquicos

k-médias

√ Partição arbitrária em 2 *clusters*: (AB) e (CD)

√ Cálculo das coordenadas $(\bar{x}_1, \bar{x}_2)$ dos centróides:

Cluster	$\bar{x}_1$	$\bar{x}_2$
AB	2	2
CD	–1	–2

Métodos Não hierárquicos

k-médias

√ Distância euclidiana de cada item

	AB	CD
A	$d(A,AB) = (5-2)^2 + (3-2)^2 =$ 10	$d(A,CD) = (5+1)^2 + (3+2)^2 =$ 61
B	$d(B,AB) = (-1-2)^2 + (1-2)^2 =$ 10	$d(B,CD) = (-1+1)^2 + (1+2)^2 =$ 9
C	$d(C,AB) = (1-2)^2 + (-2-2)^2 =$ 17	$d(C,CD) = (1+1)^2 + (-2+2)^2 =$ 4
D	$d(D,AB) = (-3-2)^2 + (-2-2)^2 =$ 41	$d(D,CD) = (-3+1)^2 + (-2+2)^2 =$ 4

	Observações	
Item	x_1	x_2
A	5	3
B	-1	1
C	1	-2
D	-3	-2

Cluster	$\bar{x}_1$	$\bar{x}_2$
AB	2	2
CD	–1	–2

B é agrupado ao *cluster* (CD)

Métodos Não hierárquicos

k-médias

√ Distância euclidiana de cada item

	A	BCD
A	$d(A,A) = (5-5)^2 + (3-3)^2 =$ 0	$d(A,BCD) = (5+1)^2 + (3+1)^2 =$ 52
B	$d(B,A) = (-1-5)^2 + (1-3)^2 =$ 40	$d(B,BCD) = (-1+1)^2 + (1+1)^2 =$ 4
C	$d(C,A) = (1-5)^2 + (-2-3)^2 =$ 41	$d(C,BCD) = (1+1)^2 + (-2+1)^2 =$ 5
D	$d(D,A) = (-3-5)^2 + (-2-3)^2 =$ 89	$d(D,BCD) = (-3+1)^2 + (-2+1)^2 =$ 5

	Observações	
Item	x_1	x_2
A	5	3
B	-1	1
C	1	-2
D	-3	-2

Cluster	$\bar{x}_1$	$\bar{x}_2$
A	5	3
BCD	–1	–1

O agrupamento é mantido e se encerra o processo

Referências

ARTES, Rinaldo; BARROSO, Lúcia Pereira. Métodos multivariados de análise estatística. São Paulo: Blucher, 2023.

JOHNSON, R. A.; WINCHERN, D. W. Applied Multivariate Statistical Analysis. Prentice Hall, 2007

FÁVERO, Luiz; FÁVERO, Patrícia. Análise de dados: técnicas multivariadas exploratórias com SPSS e STATA. Elsevier Brasil, 2017.

- Notas de aula Prof. Djalma Pessoa ENCE/IBGE
- Notas de aula Prof. Lupércio França Bessegato UFJF

GERE, Attila. Recommendations for validating hierarchical clustering in consumer sensory projects. Current Research in Food Science, v. 6, p. 100522, 2023.